Методические указания к лабораторной работе

«Обработчики прерываний»

Прерывания традиционно делятся на быстрые и медленные. Флаги радикально поменялись после версии ядра 2.6.19. Флаг, отмечающий быстрое прерывание SA_INTERRUPT, перестал существовать и был введен флаг _IRQF_TIMER. Таким образом, единственным быстрым прерыванием в настоящее время является прерывание от системного таймера. Обработчики быстрых прерываний выполняются полностью: от начала до конца на высочайших уровнях привелегий.

Обработчики медленных прерываний делятся на две части: верхнюю (top) и нижнюю (bottom) половины (half).

В настоящее время нижние половины могут быть трех типов:

- Отложенные прерывания (softirq)
- Тасклеты (tasklets)
- Очереди работ (work queue).

Драйверы регистрируют обработчик аппаратного прерывания и разрешают определенную линию irq посредством функции:

<linux/interrupt.h>

typedef irqreturn_t(*irq_handler_t)(int,void *);

Int request_irq(unsigned int irq, irq_handler_t handler, unsigned long flags, const char* name, void *dev);

Прототипы взяты из ядра 2.6.37.

Устаревший прототип. Как видно, из объявления handler убрана struct pt_regs.

int request_irq(unsigned int irq, irqreturn_t(*handler)(int, void *,
struct pt_regs *), unsigned long irqflags, const char *devname,
void *dev_id);

где: irq – номер прерывания, *handler – указатель на обработчик прерывания, irqflags – флаги, devname – ASCII текст, представляющий устройство, связанное с прерыванием, dev_id – используется прежде всего для разделения (shared) линии прерывания и ***struct pt_regs * - этот параметр в настоящее время исключен***.

Man 6.2

extern int **__must_check**
request_threaded_irq(unsigned int irq, **irq_handler_t** **handler**,
irq_handler_t **thread_fn**,
unsigned long flags, const char *name, void *dev);

```
/**
 * request_irq - Add a handler for an interrupt line
 * @irq:  The interrupt line to allocate
 * @handler:	Function to be called when the IRQ occurs.
 *		Primary handler for threaded interrupts
 *		If NULL, the default primary handler is installed
 * @flags:	Handling flags
 * @name:	Name of the device generating this interrupt
 * @dev: A cookie passed to the handler function
 *
 * This call allocates an interrupt and establishes a handler; see
 * the documentation for request_threaded_irq() for details.
 */
static inline int __must_check
request_irq(unsigned int irq, irq_handler_t handler, unsigned long flags,
            const char *name, void *dev)
{
        return request_threaded_irq(irq, handler, NULL, flags, name, dev);
}
```

Флаги, определенные на прерываниях:

```
#define IRQF_SHARED		0x00000080 /*разрешает разделение irq несколькими устройствами*/
#define IRQF_PROBE_SHARED	0x00000100 /*устанавливается абонентами, если возможны проблемы при совместном использовании irq*/
#define IRQF_TIMER		0x00000200 /*флаг, маскирующий данное прерывание как прерывание от таймера*/
#define IRQF_PERCPU		0x00000400 /*прерывание, закрепленное за определенным процессором*/
#define IRQF_NOBALANCING	0x00000800 /*флаг, запрещающий использование данного прерывания для балансировки irq*/
#define IRQF_IRQPOLL		0x00001000 /*прерывание используется для опроса*/.
#define IRQF_ONESHOT	0x00002000
#define IRQF_NO_SUSPEND	0x00004000
#define IRQF_FORCE_RESUME	0x00008000
#define IRQF_NO_THREAD	0x00010000
#define IRQF_EARLY_RESUME	0x00020000
#define IRQF_COND_SUSPEND	0x00040000
```

Флаги были изменены радикально после версии ядра 2.6.19.

extern void free_irq(unsigned int irq, void *dev);

Данные по указателю dev требуются для удаления только конкретного устройства. Указатель void позволяет передавать все, что требуется,

например указатель на handler. В результате **free_irq()** освободит линию **irq** от указанного обработчика.

Softirq

Отложенные гибкие прерывания определяются статически во время компиляции ядра. В ядре определена в файле <linux/interrupt/h> структура softirq_action (начиная с версии 2.6.37):

```
struct softirq_action
{
        void    (*action)(struct softirq_action *);
};
```

Перечень определенных в ядре гибких прерываний и предупреждение в ядре:

```
/* ПОЖАЛУЙСТА, избегайте выделения новых программных прерываний, если вам не нужны
_действительно_ высокие_частотное поточное планирование заданий. Почти для всех
целей тасклетов более чем достаточно. Ф.э. все серийные устройства ВН и др.
    ал. должны быть преобразованы в тасклеты, а не в мягкие прерывания. */

enum
{
        HI_SOFTIRQ=0,
        TIMER_SOFTIRQ,
        NET_TX_SOFTIRQ,
        NET_RX_SOFTIRQ,
        BLOCK_SOFTIRQ,
        IRQ_POLL_SOFTIRQ,
        TASKLET_SOFTIRQ,
        SCHED_SOFTIRQ,
        HRTIMER_SOFTIRQ,
        RCU_SOFTIRQ,    /* Preferable RCU should always be the last softirq */

        NR_SOFTIRQS
};
```

Тасклеты

Тасклеты — это механизм обработки нижних половин, построенный на основе механизма отложенных прерываний. Тасклеты представлены двумя типами отложенных прерываний: HI_SOFTIRQ и TASKLET_SOFTIRQ. Единственная разница между ними в том, что тасклеты типа HI_SOFTIRQ выполняются всегда раньше тасклетов типа TASKLET_SOFTIRQ.

В man 6.2.1 написано следующее:

/*

Тасклеты --- многопоточный аналог BHs.

Этот API устарел. Пожалуйста, рассмотрите возможность использования потоковых IRQ-запросов вместо этого:

https://lore.kernel.org/lkml/20200716081538.2sivhkj4hcyrusem@linutronix.de

Основная особенность, отличающая их от обычных softirqs: тасклет выполняется только на одном процессоре одновременно.

Основная особенность, отличающая их от BHs: разные тасклеты могут запускаться одновременно на разных процессорах.
Свойства:
 * Если вызывается функция tasklet_schedule(), то после этого tasklet гарантированно будет выполнен на каком-либо процессоре хотя бы один раз.
* Если тасклет уже запланирован, но его выполнение все еще не запущено, он будет выполнен только один раз.
* Если этот тасклет уже запущен на другом процессоре (или *schedule* вызывается из самого тасклета), оно переносится на более поздний срок.
* Тасклет строго сериализован по отношению к самому себе, но не по отношению к другим тасклетам. Если клиенту нужна некоторая межзадачная синхронизация, он делает это с помощью spinlocks.
 */

В ядре 6.2.1 определена структура:

```
struct tasklet_struct
{
        struct tasklet_struct *next;
        unsigned long state;
        atomic_t count;
        bool use_callback;
        union {
                void (*func)(unsigned long data);
                void (*callback)(struct tasklet_struct *t);
        };
        unsigned long data;
};
```

```
V 6.9.2
/* Tasklets --- multithreaded analogue of BHs.

   This API is deprecated. Please consider using threaded IRQs instead:
   https://lore.kernel.org/lkml/20200716081538.2sivhkj4hcyrusem@linutronix.de

   Main feature differing them of generic softirqs: tasklet
   is running only on one CPU simultaneously.

   Main feature differing them of BHs: different tasklets
   may be run simultaneously on different CPUs.

   Properties:
   * If tasklet_schedule() is called, then tasklet is guaranteed
     to be executed on some cpu at least once after this.
   * If the tasklet is already scheduled, but its execution is still not
     started, it will be executed only once.
   * If this tasklet is already running on another CPU (or schedule is called
     from tasklet itself), it is rescheduled for later.
   * Tasklet is strictly serialized wrt itself, but not
     wrt another tasklets. If client needs some intertask synchronization,
     he makes it with spinlocks.
 */

Тасклеты --- многопоточный аналог BH.

    Этот API устарел. Вместо этого рассмотрите возможность использования потоковых
IRQ: https://lore.kernel.org/lkml/20200716081538.2sivhkj4hcyrusem@linutronix.de
```

```
Основная особенность, отличающая их от обычных программных прерываний: тасклет
одновременно работает только на одном процессоре.
Основная особенность, отличающая BH: разные тасклеты могут запускаться одновременно
на разных процессорах.
    Характеристики:
    * Если вызывается tasklet_schedule(), то tasklet гарантированно
      быть выполненным на каком-либо процессоре хотя бы один раз после этого.
    * Если тасклет уже запланирован, но его выполнение еще не начато то, он будет
выполнен только один раз.
    * Если этот тасклет уже выполняется на другом процессоре (или планировщик
вызывается из самого тасклета) то, выполнение переносится на более позднее время.
    * Тасклет строго сериализуется относительно самого себя, но не
      относительно других тасклетов. Если клиенту нужна синхронизация между
задачами, он делает это с помощью спинлоков.

struct tasklet_struct
{
        struct tasklet_struct *next;
        unsigned long state;
        atomic_t count;
        bool use_callback;
        union {
                void (*func)(unsigned long data);
                void (*callback)(struct tasklet_struct *t);
        };
        unsigned long data;
};

#define DECLARE_TASKLET(name, _callback)          \
struct tasklet_struct name = {                          \
        .count = ATOMIC_INIT(0),                  \
        .callback = _callback,                          \
        .use_callback = true,                           \
}
```

Устаревшая структура:

```
struct tasklet_struct
 {
   struct tasklet_struct *next;  /* указатель на следующий тасклет в     списке
                                    */
   unsigned long state;        /* состояние тасклета */
   atomic_t count;             /* счетчик ссылок */
   void (*func) (unsigned long); /* функция-обработчик тасклета*/
   unsigned long data; /* аргумент функции-обработчика тасклета */
);
```

Тасклеты в отличие от softirq могут быть зарегистрированы как статически, так и динамически.

Статически тасклеты создаются с помощью двух макросов (man 6.2.1):

```
#define DECLARE_TASKLET(name, _callback)                \
struct tasklet_struct name = {                          \
        .count = ATOMIC_INIT(0),                        \
        .callback = _callback,                          \
        .use_callback = true,                           \
}
```

```
#define DECLARE_TASKLET_DISABLED(name, _callback)   \
struct tasklet_struct name = {                      \
        .count = ATOMIC_INIT(1),                    \
        .callback = _callback,                      \
        .use_callback = true,                       \
}
```

DECLARE_TASKLET(name, func, data)
DECLARE_TASKLET_DISABLED(name, func, data);

Оба макроса статически создают экземпляр структуры struct tasklet_struct с указанным именем (name).

Например.
DECLARE_TASKLET(my_tasklet, tasklet_handler);

Эта строка эквивалентна следующему объявлению:

```
struct tasklet_struct rny_tasklet = {NULL, 0, ATOMIC_INIT(0),
                                     tasklet_handler};
```

В данном примере создается тасклет с именем my_tasklet , который разрешен для выполнения. Функция tasklet_handler будет обработчиком этого тасклета.
Поле dev отсутствует в текущих ядрах. Значение параметра dev передается в функцию-обработчик при вызове данной функции.

В текущих ядрах определены:

```
#define from_tasklet(var, callback_tasklet, tasklet_fieldname)          \
        container_of(callback_tasklet, typeof(*var), tasklet_fieldname)

#define DECLARE_TASKLET_OLD(name, _func)                                \
struct tasklet_struct name = {                                          \
        .count = ATOMIC_INIT(0),                                        \
        .func = _func,                                                  \
}
#define DECLARE_TASKLET_DISABLED_OLD(name, _func)       \
struct tasklet_struct name = {                          \
        .count = ATOMIC_INIT(1),                        \
        .func = _func,                                  \
}
```

При динамическом создании тасклета объявляется указатель на структуру struct tasklet_struct *t, а затем для инициализации вызывается функция (man):

extern void **tasklet_init**(struct **tasklet_struct** *t, void (***func**)(unsigned long), unsigned long data);

Пример:
tasklet_init(t , tasklet_handler , data) ;

Тасклеты должны быть запланированы для выполнения. Тасклеты могут быть запланированы на выполнение функциями:
tasklet_schedule(struct tasklet_struct *t);
tasklet_hi_sheduler(struct tasklet_struct *t);

void tasklet_hi_schedule_first(struct tasklet_struct *t); /* вне очереди */

---

man 6.2.1.

```
extern void __tasklet_schedule(struct tasklet_struct *t);

static inline void tasklet_schedule(struct tasklet_struct *t)
{
        if (!test_and_set_bit(TASKLET_STATE_SCHED, &t->state))
                __tasklet_schedule(t);
}
extern void __tasklet_hi_schedule(struct tasklet_struct *t);
static inline void tasklet_hi_schedule(struct tasklet_struct *t)
{
        if (!test_and_set_bit(TASKLET_STATE_SCHED, &t->state))
                __tasklet_hi_schedule(t);
}
```

Эти функции очень похожи и отличие состоит в том, что одна функция использует отложенное прерывание с номером TASKLET_SOFTIRQ, а другая — с номером HI_SOFTIRQ.
Когда tasklet запланирован, ему выставляется состояние **TASKLET_STATE_SCHED**, и тон добавляется в очередь. Пока он находится в этом состоянии, запланировать его еще раз не получится, т.е. в этом случае просто ничего не произойдет. Tasklet не может находиться сразу в нескольких местах очереди на планирование, которая организуется через поле next структуры tasklet_struct.
После того, как тасклет был запланирован, он выполниться только один раз.
Man 6.2.1

```
extern void tasklet_kill(struct tasklet_struct *t);
extern void tasklet_init(struct tasklet_struct *t, void (*func)(unsigned long), unsigned long data);
extern void tasklet_setup(struct tasklet_struct *t, void (*callback)(struct tasklet_struct *));
```

Пример объявления и планирования тасклета.

```
/* Declare a Tasklet (the Bottom-Half) */
void tasklet_function( unsigned long data );

DECLARE_TASKLET(tasklet_example,tasklet_function,tasklet_data);
```

```
...

/* Schedule the Bottom-Half */
tasklet_schedule( &tasklet_example );
```

Пример с обработчиком прерывания:

Следует обратить внимание на современный мануал по аппаратным прерываниям:

```
extern int __must_check
request_threaded_irq(unsigned int irq, irq_handler_t handler,
                     irq_handler_t thread_fn,
                     unsigned long flags, const char *name, void *dev);

/**
 * request_irq - Add a handler for an interrupt line
 * @irq:  The interrupt line to allocate
 * @handler:    Function to be called when the IRQ occurs.
 *              Primary handler for threaded interrupts
 *              If NULL, the default primary handler is installed
 * @flags:      Handling flags
 * @name:       Name of the device generating this interrupt
 * @dev: A cookie passed to the handler function
 *
 * This call allocates an interrupt and establishes a handler; see
 * the documentation for request_threaded_irq() for details.
 */
static inline int __must_check
request_irq(unsigned int irq, irq_handler_t handler, unsigned long flags,
            const char *name, void *dev)
{
        return request_threaded_irq(irq, handler, NULL, flags, name, dev);
}
```

```
irqreturn_t irq_handler(int irq, void *dev, struct pt_regs *regs)
{
   if(irq==define_irq)
    {
        tasklet_schedule(&my_tasklet);
        return IRQ_HANDLED;// прерывание обработано
    }
   else return IRQ_NONE; // прерывание не обработано
}
int init_module(void)
{
   return request_irq(define_irq, /*номер irq*/
```

(irq_handler_t)irq_handler,/*наш обработчик*/
IRQF_SHARED,
“test_my_irq_handler”,/*имя устройства*/
(void *)(irq_handler)); /* void* dev_id – идентификатор устройства. Может быть NULL, но тогда его невозможно будет идентифицировать для отключения с помощью free_irq. Т.к. это указатель на void, может указывать на что угодно. Обычно используется указатель на структуру описывающую устройство. В нашем случае используем указатель на обработчик.*/

…..
}
….

Tasklet можно активировать и деактивировать функциями:

void tasklet_disable_nosync(struct tasklet_struct *t); /* деактивация */
tasklet_disable(struct tasklet_struct *t); /* с ожиданием завершения работы tasklet’a */
tasklet_enable(struct tasklet_struct *t); /* активация */

Не использовать в новом коде. Отключение тасклетов из атомарных контекстов чревато ошибками, и его следует избегать.

```
static inline void tasklet_disable_in_atomic(struct tasklet_struct *t)
{
        tasklet_disable_nosync(t);
        tasklet_unlock_spin_wait(t);
        smp_mb();
}

static inline void tasklet_disable(struct tasklet_struct *t)
{
        tasklet_disable_nosync(t);
        tasklet_unlock_wait(t);
        smp_mb();
}
static inline void tasklet_enable(struct tasklet_struct *t)
{
        smp_mb__before_atomic();
        atomic_dec(&t->count);
}
```

Если tasklet деактивирован, его по-прежнему можно добавить в очередь на планирование, но исполняться на процессоре он не будет до тех пор, пока не будет вновь активирован. Причем, если tasklet был деактивирован несколько раз, то он должен быть ровно столько же раз активирован, поле count в структуре как раз для этого.

tasklet_trylock() выставляет tasklet'у состояние **TASKLET_STATE_RUN** и тем самым блокирует tasklet, что предотвращает исполнение одного и того же tasklet'а на разных CPU.

tasklet_kill (struct tasklet_struct *t) – ждет завершения тасклета и удаляет тасклет из очереди на выполнение только в контексте процесса.
tasklet_kill_immediate (struct tasklet_struct *t, unsigned int cpu) – удаляет тасклет в любом случае.
Причем, убит он будет только после того, как tasklet исполнится, если он уже запланирован.

Простой пример тасклета в контексте модуля ядра ***без обработчика прерывания***:

```
#include <linux/kernel.h>
#include <linux/module.h>
#include <linux/interrupt.h>

MODULE_LICENSE("GPL");

char my_tasklet_data[]="my_tasklet_function was called";

/* Bottom Half Function */
void my_tasklet_function( unsigned long data )
{
  printk( "%s\n", (char *)data );
  return;
}

DECLARE_TASKLET( my_tasklet, my_tasklet_function,
            (unsigned long) &my_tasklet_data );

int init_module( void )
{
  /* Schedule the Bottom Half */
  tasklet_schedule( &my_tasklet );

  return 0;
}

void cleanup_module( void )
{
  /* Stop the tasklet before we exit */
  tasklet_kill( &my_tasklet );

  return;
}
```

Задание:

- Написать загружаемый модуль ядра, в котором зарегистрировать обработчик аппаратного прерывания с флагом IRQF_SHARED.
- Инициализировать тасклет.
- В **обработчике прерывания (обязательно)** запланировать тасклет на выполнение.
- Вывести информацию о тасклете используя, или printk(), или seq_file interface - <linux/seq_file.h> (Jonathan Corber: http://lwn.net//Articales//driver-porting/).

Очереди работ

Основные понятия CMWQ (Concurrency Managed Workqueue)
Несколько объектов, связанных с очередью работ (***workqueue),*** представлены в ядре соответствующими структурами:

1) Работа (work);
2) Очередь работ (workqueue) – коллекция work. Workqueue и work относятся как один-ко-многим;
3) Рабочий (worker). Worker соответствует потоку ядра worker_thread;
4) Пул рабочих потоков (worker_pool) это – набор рабочих (worker). Worker_pool и worker относятся как «один ко многим»;
5) Pwd (pool_workqueue) это – посредник, который отвечает за отношение workqueue и worker_pool: workqueue и pwd является отношением один-ко-многим, а pwd и worker_pool – отношение один-к-одному.

Очередь работ создается функцией (см. приложение 1):
int alloc_workqueue(char *name, unsigned int flags, int max_active);

- name - имя очереди (workqueue), но в отличие от старых реализаций потоков с этим именем не создается
- flags - флаги определяют как очередь работ будет выполняться
- max_active - ограничивает число задач (work) из некоторой очереди, которые могут выполняться на одном CPU.

```
/**
 * alloc_workqueue - allocate a workqueue
 * @fmt: printf format for the name of the workqueue
 * @flags: WQ_* flags
 * @max_active: max in-flight work items, 0 for default
 * remaining args: args for @fmt
 *
 * Allocate a workqueue with the specified parameters.  For detailed
 * information on WQ_* flags, please refer to
 * Documentation/core-api/workqueue.rst.
 *
 * RETURNS:
```

```
 * Pointer to the allocated workqueue on success, %NULL on failure.
 */
__printf(1, 4) struct workqueue_struct *
alloc_workqueue(const char *fmt, unsigned int flags, int max_active, ...);
```

Флаги

enum
{
  WQ_UNBOUND =1<<1,/*not bound to any cpu*/
  WQ_FREEZABLE =1<<2,/*freez during suspend*/
  WQ_MEM_RECLAIM =1<<3,/*may be used for memory reclaim*/
  WQ_HIGHPRI =1<<4,/*high priority*/
  WQ_CPU_INTENSIVE =1<<5,/*cpu intensive workqueue*/
  WQ_SYSFS =1<<6,/*visible in sysfs, see
wq_sysfs_register()*/
 WQ_POWER_EFFICIENT =1<<7 …
 WQ_MAX_ACTIVE =512
…
}

Man 6.2.2

```
/*
 * Workqueue flags and constants.  For details, please refer to
 * Documentation/core-api/workqueue.rst.
 */
enum {
        WQ_UNBOUND              = 1 << 1, /* not bound to any cpu */
        WQ_FREEZABLE            = 1 << 2, /* freeze during suspend */
        WQ_MEM_RECLAIM          = 1 << 3, /* may be used for memory reclaim */
        WQ_HIGHPRI              = 1 << 4, /* high priority */
        WQ_CPU_INTENSIVE = 1 << 5, /* cpu intensive workqueue */
        WQ_SYSFS         = 1 << 6, /* visible in sysfs, see
workqueue_sysfs_register() */

        /*
         * Per-cpu workqueues are generally preferred because they tend to
         * show better performance thanks to cache locality.  Per-cpu
         * workqueues exclude the scheduler from choosing the CPU to
         * execute the worker threads, which has an unfortunate side effect
         * of increasing power consumption.
         *
         * The scheduler considers a CPU idle if it doesn't have any task
         * to execute and tries to keep idle cores idle to conserve power;
         * however, for example, a per-cpu work item scheduled from an
         * interrupt handler on an idle CPU will force the scheduler to
         * execute the work item on that CPU breaking the idleness, which in
         * turn may lead to more scheduling choices which are sub-optimal
         * in terms of power consumption.
         *
         * Workqueues marked with WQ_POWER_EFFICIENT are per-cpu by default
         * but become unbound if workqueue.power_efficient kernel param is
         * specified.  Per-cpu workqueues which are identified to
         * contribute significantly to power-consumption are identified and
         * marked with this flag and enabling the power_efficient mode
         * leads to noticeable power saving at the cost of small
         * performance disadvantage.
```

Обычно предпочтительнее использовать рабочие очереди для каждого процессора, поскольку они имеют тенденцию

```
   * показывать лучшую производительность благодаря локальности кэша.   На
процессор рабочие очереди исключают возможность планировщика выбирать процессор для
выполнения рабочих потоков, что имеет неприятный побочный эффект - увеличения
энергопотребления.
   * Планировщик считает процессор простаивающим, если у него нет выполняемых задач
и пытается оставить простаивающие ядра в режиме ожидания для экономии энергии;
   * однако, например, рабочий элемент для каждого процессора, запланированный из
   * обработчика прерывания на простаивающем процессоре заставит планировщик
выполнить рабочий элемент на этом процессоре, прервав режим простоя, что в итоге
может привести к большему количеству вариантов планирования, которые не являются
оптимальными по энергопотреблению.
   *
   * Рабочие очереди, отмеченные WQ_POWER_EFFICIENT, по умолчанию рассчитаны для
каждого процессора. но становится несвязанными, если параметр ядра
workqueue.power_efficient специфицирован. Рабочие очереди для каждого процессора,
которые, как установлено, вносят значительный вклад в энергопотребление,
идентифицируются и помечаются этим флагом, а включение режима power_efficient
приводит к заметной экономии энергии за счет небольшого снижения
производительности.       *
         * http://thread.gmane.org/gmane.linux.kernel/1480396
         */
        WQ_POWER_EFFICIENT      = 1 << 7,

        __WQ_DESTROYING         = 1 << 15, /* internal: workqueue is destroying */
        __WQ_DRAINING           = 1 << 16, /* internal: workqueue is draining */
        __WQ_ORDERED            = 1 << 17, /* internal: workqueue is ordered */
        __WQ_LEGACY             = 1 << 18, /* internal: create*_workqueue() */
        __WQ_ORDERED_EXPLICIT   = 1 << 19, /* internal: alloc_ordered_workqueue()
*/

        WQ_MAX_ACTIVE           = 512,    /* I like 512, better ideas? */
        WQ_MAX_UNBOUND_PER_CPU  = 4,      /* 4 * #cpus for unbound wq */
        WQ_DFL_ACTIVE           = WQ_MAX_ACTIVE / 2,
};

/* unbound wq's aren't per-cpu, scale max_active according to #cpus */
#define WQ_UNBOUND_MAX_ACTIVE     \
        max_t(int, WQ_MAX_ACTIVE, num_possible_cpus() * WQ_MAX_UNBOUND_PER_CPU)

/*
 * System-wide workqueues which are always present.
 *
 * system_wq is the one used by schedule[_delayed]_work[_on]().
 * Multi-CPU multi-threaded.  There are users which expect relatively
 * short queue flush time.  Don't queue works which can run for too
 * long.
 *
 * system_highpri_wq is similar to system_wq but for work items which
 * require WQ_HIGHPRI.
 *
 * system_long_wq is similar to system_wq but may host long running
 * works.  Queue flushing might take relatively long.
 *
 * system_unbound_wq is unbound workqueue.  Workers are not bound to
 * any specific CPU, not concurrency managed, and all queued works are
 * executed immediately as long as max_active limit is not reached and
 * resources are available.
 *
 * system_freezable_wq is equivalent to system_wq except that it's
 * freezable.
 *
 * *_power_efficient_wq are inclined towards saving power and converted
 * into WQ_UNBOUND variants if 'wq_power_efficient' is enabled; otherwise,
 * they are same as their non-power-efficient counterparts - e.g.
 * system_power_efficient_wq is identical to system_wq if
```

```
* 'wq_power_efficient' is disabled.  See WQ_POWER_EFFICIENT for more info.
*/
```

- **WQ_UNBOUND**: По наличию этого флага очереди (workqueue) делятся на привязанные (normal) и непривязанные (unbound). В привязанных очередях work'и при добавлении привязываются к текущему CPU, то есть в таких очередях work'и исполняются на том ядре, которое его планирует (на котором выполнялся обработчик прерывания). В этом плане привязанные очереди напоминают tasklet'ы. Привязанные очереди работ исключают выбор планировщиком процессора для выполнения рабочего потока, что имеет неприятный побочный эффект увеличения энергопотребления. Привязанные рабочие очереди, как правило, предпочтительнее из-за лучших показателей локализации кеша. Данный флаг отключает это поведение, позволяя отправлять заданные рабочие очереди на любой процессор. В непривязанных очередях work'и могут исполняться на любом ядре. Флаг предназначен для ситуаций, когда задачи могут выполняться в течение длительного времени, причем так долго, что лучше разрешить планировщику управлять своим местоположением. В настоящее время единственным пользователем является код обработки объектов в подсистеме FS-Cache.
- **WQ_FREEZEABLE**: работа будет заморожена, когда система будет приостановлена. Очевидно, что рабочие задания, которые могут запускать задачи как часть процесса приостановки / возобновления, не должны устанавливать этот флаг.
- **WQ_RESCUER**: код workqueue отвечает за гарантированное наличие потока для запуска worker'а в очереди. Он используется, например, в коде драйвера ATA, который всегда должен иметь возможность запускать свои процедуры завершения ввода-вывода.
- **WQ_HIGHPRI**: задания, представленные в такой workqueue, будут поставлены в начало очереди и будут выполняться (почти) немедленно. В отличие от обычных задач, высокоприоритетные задачи не ждут появления ЦП; они будут запущены сразу. Это означает, что несколько задач, отправляемых в очередь с высоким приоритетом, могут конкурировать друг с другом за процессор.
- **WQ_CPU_INTENSIVE**: имеет смысл только для привязанных очередей. Этот флаг— отказ от участия в дополнительной организации параллельного исполнения. Задачи в такой workqueue могут использовать много процессорного времени. Интенсивно использующие процессорное время worker'ы будут задерживаться.

Также может использоваться вызов create_workqueue:

```
#define create_workqueue(name)                                  \
```

alloc_workqueue("%s", __WQ_LEGACY | WQ_MEM_RECLAIM, 1, (name))

Например:

```
static int __init synthesizer_init(void)
{
    printk(KERN_INFO "Init synth.");
   // регистрация обработчика прерывания
   int res = request_irq(irq, irq_handler, IRQF_SHARED,
              synth.name, &synth);
    if (res == 0)
    {
       printk(KERN_INFO "Keyboard irq handler was registered
             successfully.");
      // создание workqueue
      synth.wq = alloc_workqueue("sound_player", WQ_UNBOUND,
0);
      if (synth.wq)
          printk(KERN_INFO "Workqueue was allocated
successfully");
     }
     else
      {
        free_irq(synth.keyboard_irq, &synth);
        printk(KERN_ERR "Workqueue allocation failed");
        return -ENOMEM;
       }
}
```

```
/*
* Очередь отложенных действий, связанная с процессором:
*/
struct cpu_workqueue_struct
{
  spinlock_t lock; /* Очередь для защиты данной структуры */
  long remove_sequence; /* последний добавленный элемент
 (следующий для запуска ) */
  long insert_sequence; /* следующий элемент для добавления */
  struct list_head worklist; /* список действий */
  wait_queue_head_t more_work;
  wait_queue_head_t work_done;
   struct workqueue_struct *wq;  /* соответствующая структура
                                    workqueue_struct */
   task_t *thread; /* соответствующий поток */
```

int run_depth; /* глубина рекурсии функции run_workqueue() */
};

Заметим, что каждый *mun* рабочих потоков имеет одну, связанную с этим типом структуру workqueue_struct. Внутри этой структуры имеется по одному экземпляру структуры cpu_workqueue_struct для каждого рабочего потока и, следовательно, для каждого процессора в системе, так как существует только один рабочий поток каждого типа на каждом процессоре.

work item (или просто work) — это структура, описывающая функцию (например, обработчик нижней половины), которую надо запланировать. Её можно воспринимать как аналог структуры tasklet.
Для того, чтобы поместить задачу в очередь работ надо заполнить (инициализировать) структуру:

```
struct work_struct {
        atomic_long_t data;
        struct list_head entry;
        work_func_t func;
#ifdef CONFIG_LOCKDEP
        struct lockdep_map lockdep_map;
#endif
};
```

Структура work_struct представляет задачу (обработчик нижней половины) в очереди работ.

Поместить задачу в очередь работ можно во время компиляции (статически):
DECLARE_WORK(name, void (*func)(void *));
где: name – имя структуры work_struct, func – функция, которая вызывается из workqueue – обработчик нижней половины.

```
#define DECLARE_WORK(n, f)                                              \
        struct work_struct n = __WORK_INITIALIZER(n, f)

#define DECLARE_DELAYED_WORK(n, f)                                      \
        struct delayed_work n = __DELAYED_WORK_INITIALIZER(n, f, 0)
```

Если требуется задать структуру work_struct динамически, то необходимо использовать следующие два макроса:
INIT_WORK(sruct work_struct *work, void (*func)(void),void *data);

```
#define INIT_WORK(_work, _func)                                         \
        __INIT_WORK((_work), (_func), 0)
```

PREPARE_WORK(sruct work_struct *work, void (*func)(void),void *data);

После того, как будет инициализирована структура для объекта work, следующим шагом будет помещение этой структуры в очередь работ. Это

можно сделать несколькими способами. Во-первых, просто добавить работу (объект work) в очередь работ с помощью функции queue_work (которая назначает работу текущему процессору). Можно с помощью функции queue_work_on указать процессор, на котором будет выполняться обработчик.

```
int queue_work( struct workqueue_struct *wq, struct work_struct *work );
int queue_work_on( int cpu, struct workqueue_struct *wq, struct work_struct *work );
```

Две дополнительные функции обеспечивают те же функции для отложенной работы (в которой инкапсулирована структура work_struct и таймер, определяющий задержку).

```
int queue_delayed_work( struct workqueue_struct *wq,
                struct delayed_work *dwork, unsigned long delay );

int queue_delayed_work_on( int cpu, struct workqueue_struct *wq,
                struct delayed_work *dwork, unsigned long delay );
```

Кроме того, можно использовать глобальное ядро - глобальную очередь работ с четырьмя функциями, которые работают с этой очередью работ. Эти функции имитируют предыдущие функции , за исключением лишь того, что вам не нужно определять структуру очереди работ.

```
int schedule_work( struct work_struct *work );
int schedule_work_on( int cpu, struct work_struct *work );

int scheduled_delayed_work( struct delayed_work *dwork, unsigned long delay );
int scheduled_delayed_work_on(
            int cpu, struct delayed_work *dwork, unsigned long delay );
```

Есть также целый ряд вспомогательных функций, которые можно использовать, чтобы принудительно завершить (flush) или отменить работу из очереди работ. Для того, чтобы принудительно завершить конкретный элемент work и блокировать прочую обработку прежде, чем работа будет закончена, вы можете использовать функцию flush_work. Все работы в данной очереди работ могут быть принудительно завершены с помощью функции flush_workqueue. В обоих случаях вызывающий блок блокируется до тех пор, пока операция не будет завершена. Для того, чтобы принудительно завершить глобальную очередь работ ядра, вызовите функцию flush_scheduled_work.

int flush_work(struct work_struct *work);
int flush_workqueue(struct workqueue_struct *wq);
void flush_scheduled_work(void);

Можно отменить работу, если она еще не выполнена обработчиком. Обращение к функции cancel_work_sync завершит работу в очереди, либо возникнет блокировка до тех пор, пока не будет завершен обратный вызов (если работа уже выполняется обработчиком). Если работа отложена, вы можете использовать вызов функции cancel_delayed_work_sync.

int cancel_work_sync(struct work_struct *work);
int cancel_delayed_work_sync(struct delayed_work *dwork);

Наконец, можно выяснить приостановлен ли элемент work (еще не обработан обработчиком) с помощью обращения к функции work_pending илиdelayed_work_pending.

work_pending(work);

```
/**
 * work_pending - Find out whether a work item is currently pending
 * @work: The work item in question
 */
#define work_pending(work) \
        test_bit(WORK_STRUCT_PENDING_BIT, work_data_bits(work))
```

delayed_work_pending(work);

```
/**
 * delayed_work_pending - Find out whether a delayable work item is currently
 * pending
 * @w: The work item in question
 */
#define delayed_work_pending(w) \
        work_pending(&(w)->work)
```

Пример, в котором создаются две работы для одной очереди работ.

```
#include <linux/kernel.h>
#include <linux/module/h>
#include <linux/workqueue.h>
MODULE_LICENSE(“GPL”);
static struct workqueue_struct *my_wq; //очередь работ
typedef struct
{
  struct work_struct my_work;
  int x;
} my_work_t;
my_work_t  *work1, *work2;
```

```
static void my_wq_function(struct work_struct *work) // вызываемая функция
{
  my_work_t *my_work = (my_work_t *)work;
  printk(“my_work.x %d\n”, my_work->x);
  kfree((void*)work);
  return;
}
int init_module(void)
{
  int ret;
  my_wq = create_workqueue(“my_queue”);//создание очереди работ
  if(my_wq)
   {
     Work1 = (my_work_t *)kmalloc(sizeof( my_work_t),GFP_KERNEL);
     if (work1)
       {
          /* задача (item 1)*/
         INIT_WORK((struct work_struct)work, my_wq_function);
         work1->x = 1;
        ret = queue_work(my_wq, (struct work_struct *)work1);
       }

      work2 = (my_work_t *)kmalloc(sizeof( my_work_t),GFP_KERNEL);
     if (work2)
       {
         /* задача (item 2)*/
         INIT_WORK((struct work_struct)work, my_wq_function);
         work->x = 1;
        ret = queue_work(my_wq, (struct work_struct *)work2);
       }
     }
   return 0;
}
…
```

Задание:

- Написать загружаемый модуль ядра, в котором регистрируется обработчик аппаратного прерывания с флагом IRQF_SHARED.
- Инициализировать не менее двух очередей работ.
- В обработчике прерывания запланировать очереди работ на выполнение.
- Одна из очередей должна блокироваться некоторое время.
- Вывести информацию об очереди работ используя, или printk(), или seq_file interface - <linux/seq_file.h> (Jonathan Corber: http://lwn.net//Articales//driver-porting/).

Приложение 1

```
/*
 * The externally visible workqueue.  It relays the issued work items to
 * the appropriate worker_pool through its pool_workqueues.
 */
struct workqueue_struct {
        struct list_head pwqs;          /* WR: all pwqs of this wq */
        struct list_head list;          /* PR: list of all workqueues */

        struct mutex            mutex;          /* protects this wq */
        int                     work_color;     /* WQ: current work color */
        int                     flush_color;    /* WQ: current flush color */
        atomic_t        nr_pwqs_to_flush; /* flush in progress */
        struct wq_flusher       *first_flusher; /* WQ: first flusher */
        struct list_head flusher_queue;   /* WQ: flush waiters */
        struct list_head flusher_overflow; /* WQ: flush overflow list */

        struct list_head maydays;/* MD: pwqs requesting rescue */
        struct worker           *rescuer;       /* MD: rescue worker */

        int                     nr_drainers;    /* WQ: drain in progress */
        int                     saved_max_active; /* WQ: saved pwq max_active */

        struct workqueue_attrs  *unbound_attrs;  /* PW: only for unbound wqs */
        struct pool_workqueue   *dfl_pwq;       /* PW: only for unbound wqs */

#ifdef CONFIG_SYSFS
        struct wq_device *wq_dev;/* I: for sysfs interface */
#endif
#ifdef CONFIG_LOCKDEP
        char                    *lock_name;
        struct lock_class_key   key;
        struct lockdep_map      lockdep_map;
#endif
        char                    name[WQ_NAME_LEN]; /* I: workqueue name */

        /*
         * Destruction of workqueue_struct is RCU protected to allow walking
         * the workqueues list without grabbing wq_pool_mutex.
         * This is used to dump all workqueues from sysrq.
         */
        struct rcu_head         rcu;

        /* hot fields used during command issue, aligned to cacheline */
        unsigned int            flags ____cacheline_aligned; /* WQ: WQ_* flags */
        struct pool_workqueue __percpu *cpu_pwqs; /* I: per-cpu pwqs */
        struct pool_workqueue __rcu *numa_pwq_tbl[]; /* PWR: unbound pwqs indexed
by node */
};


struct work_struct {
        atomic_long_t data;
        struct list_head entry;
        work_func_t func;
#ifdef CONFIG_LOCKDEP
        struct lockdep_map lockdep_map;
#endif
};

#ifdef CONFIG_LOCKDEP
```

```
#define __INIT_WORK(_work, _func, _onstack)                                \
        do {                                                               \
                static struct lock_class_key __key;                        \
                                                                           \
                __init_work((_work), _onstack);                            \
                (_work)->data = (atomic_long_t) WORK_DATA_INIT(); \
                lockdep_init_map(&(_work)->lockdep_map, "(work_completion)"#_work,
&__key, 0); \
                INIT_LIST_HEAD(&(_work)->entry);                   \
                (_work)->func = (_func);                           \
        } while (0)
#else
#define __INIT_WORK(_work, _func, _onstack)                                \
        do {                                                               \
                __init_work((_work), _onstack);                            \
                (_work)->data = (atomic_long_t) WORK_DATA_INIT(); \
                INIT_LIST_HEAD(&(_work)->entry);                   \
                (_work)->func = (_func);                           \
        } while (0)
#endif

#define INIT_WORK(_work, _func)                                            \
        __INIT_WORK((_work), (_func), 0)

#define INIT_WORK_ONSTACK(_work, _func)                                    \
        __INIT_WORK((_work), (_func), 1)

#define __INIT_DELAYED_WORK(_work, _func, _tflags)                         \
        do {                                                               \
                INIT_WORK(&(_work)->work, (_func));                        \
                __init_timer(&(_work)->timer,                              \
                             delayed_work_timer_fn,                        \
                             (_tflags) | TIMER_IRQSAFE);           \
        } while (0)

#define __INIT_DELAYED_WORK_ONSTACK(_work, _func, _tflags)         \
        do {                                                               \
                INIT_WORK_ONSTACK(&(_work)->work, (_func));                \
                __init_timer_on_stack(&(_work)->timer,                     \
                                      delayed_work_timer_fn,               \
                                      (_tflags) | TIMER_IRQSAFE);\
        } while (0)

#define INIT_DELAYED_WORK(_work, _func)                                    \
        __INIT_DELAYED_WORK(_work, _func, 0)

#define INIT_DELAYED_WORK_ONSTACK(_work, _func)                            \
        __INIT_DELAYED_WORK_ONSTACK(_work, _func, 0)

#define INIT_DEFERRABLE_WORK(_work, _func)                                 \
        __INIT_DELAYED_WORK(_work, _func, TIMER_DEFERRABLE)

#define INIT_DEFERRABLE_WORK_ONSTACK(_work, _func)                         \
        __INIT_DELAYED_WORK_ONSTACK(_work, _func, TIMER_DEFERRABLE)

#define INIT_RCU_WORK(_work, _func)                                        \
        INIT_WORK(&(_work)->work, (_func))

#define INIT_RCU_WORK_ONSTACK(_work, _func)                                \
        INIT_WORK_ONSTACK(&(_work)->work, (_func))
```

```
/* Возвращает:
* указатель на выделенный workqueue при успешном выполнении, %NULL при сбое.
* /
```

```
struct workqueue_struct * alloc_workqueue( const char *fmt,
                                           unsigned int flags,
                                           int max_active, ...);
```

```
#define create_workqueue(name)                                          \
        alloc_workqueue("%s", __WQ_LEGACY | WQ_MEM_RECLAIM, 1, (name))
```

```
extern void destroy_workqueue(struct workqueue_struct *wq);

extern void flush_workqueue(struct workqueue_struct *wq);

/* This puts a job in the kernel-global workqueue if it was not already
 * queued and leaves it in the same position on the kernel-global
 * workqueue otherwise.
 */
static inline bool schedule_work(struct work_struct *work)
{
        return queue_work(system_wq, work);
}

/* After waiting for a given time this puts a job in the kernel-global
 * workqueue.
 */
static inline bool schedule_delayed_work(struct delayed_work *dwork,
                                         unsigned long delay)
{
        return queue_delayed_work(system_wq, dwork, delay);
}

/* After waiting for a given time this puts a job in the kernel-global
 * workqueue on the specified CPU.
 */
static inline bool schedule_delayed_work_on(int cpu, struct delayed_work *dwork,
                                            unsigned long delay)
{
        return queue_delayed_work_on(cpu, system_wq, dwork, delay);
}

/* In most situations flushing the entire workqueue is overkill; you merely
 * need to know that a particular work item isn't queued and isn't running.
 * In such cases you should use cancel_delayed_work_sync() or
 * cancel_work_sync() instead.
 */
static inline void flush_scheduled_work(void)
{
        flush_workqueue(system_wq);
}


/* struct worker is defined in workqueue_internal.h */

struct worker_pool {
        raw_spinlock_t          lock;           /* the pool lock */
        int                     cpu;            /* I: the associated cpu */
        int                     node;           /* I: the associated node ID */
        int                     id;             /* I: pool ID */
        unsigned int            flags;          /* X: flags */

        unsigned long           watchdog_ts;    /* L: watchdog timestamp */

        /*
         * The counter is incremented in a process context on the associated CPU
```

```
         * w/ preemption disabled, and decremented or reset in the same context
         * but w/ pool->lock held. The readers grab pool->lock and are
         * guaranteed to see if the counter reached zero.
         */
        int                     nr_running;

        struct list_head worklist;        /* L: list of pending works */

        int                     nr_workers;     /* L: total number of workers */
        int                     nr_idle;/* L: currently idle workers */

        struct list_head idle_list;       /* L: list of idle workers */
        struct timer_list       idle_timer;     /* L: worker idle timeout */
        struct timer_list       mayday_timer;   /* L: SOS timer for workers */

        /* a workers is either on busy_hash or idle_list, or the manager */
        DECLARE_HASHTABLE(busy_hash, BUSY_WORKER_HASH_ORDER);
                                                /* L: hash of busy workers */

        struct worker           *manager;       /* L: purely informational */
        struct list_head workers;/* A: attached workers */
        struct completion       *detach_completion; /* all workers detached */

        struct ida              worker_ida;     /* worker IDs for task name */

        struct workqueue_attrs  *attrs;         /* I: worker attributes */
        struct hlist_node       hash_node;      /* PL: unbound_pool_hash node */
        int                     refcnt;         /* PL: refcnt for unbound pools
*/

        /*
         * Destruction of pool is RCU protected to allow dereferences
         * from get_work_pool().
         */
        struct rcu_head         rcu;
};
```

Приложение 2

Иллюстрации к soft irq **NET_RX__SOFTIRQ**

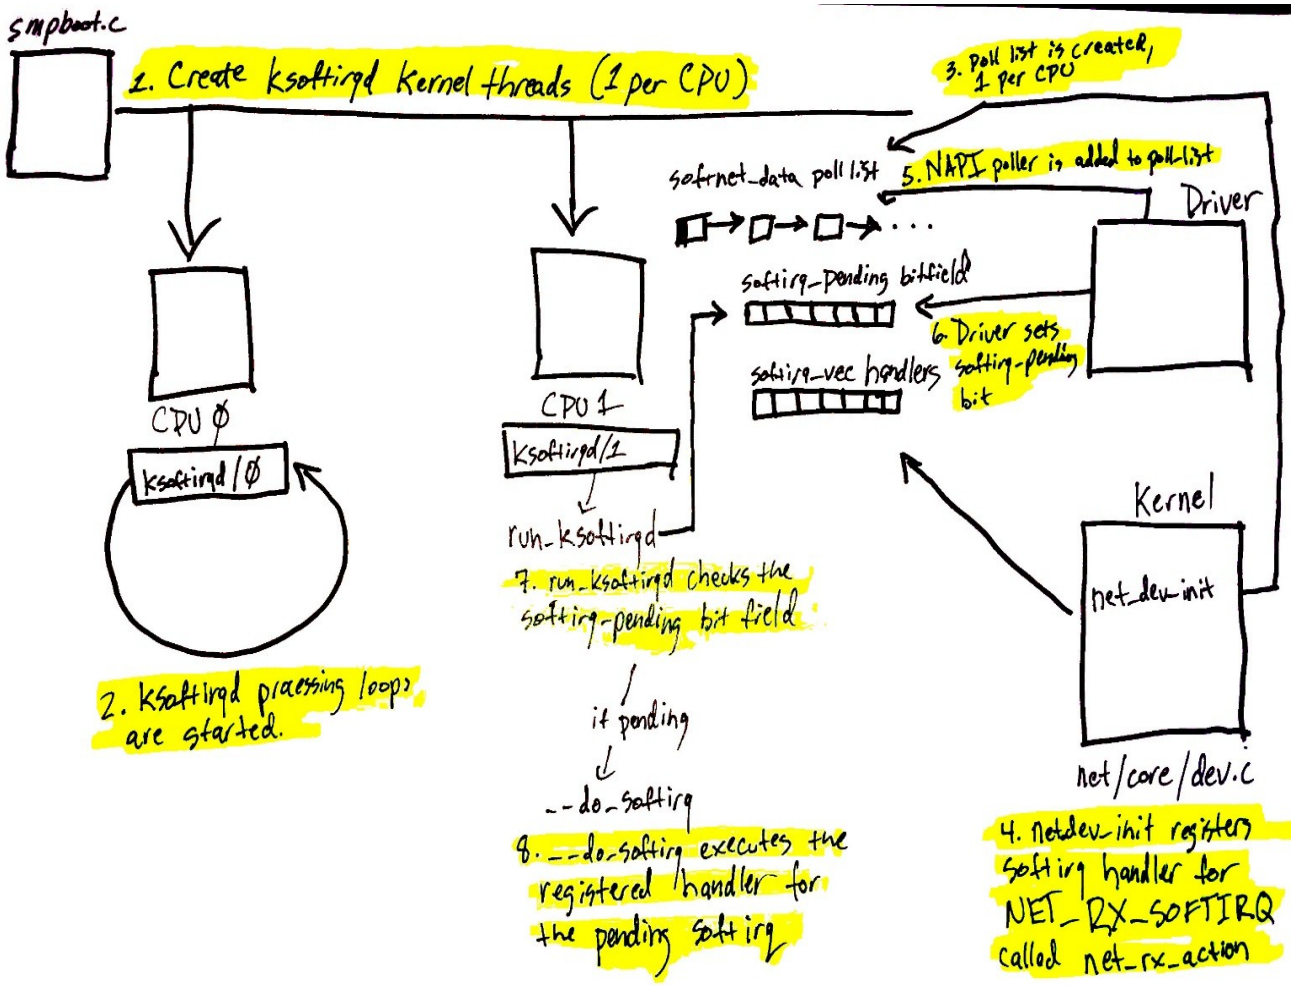
smpboot.c
1. Create ksoftirqd kernel threads (1 per CPU)
3. Poll list is created, 1 per CPU
softnet_data poll list
5. NAPI poller is added to poll_list
Driver
softirq_pending bitfield
6. Driver sets softirq-pending bit
softirq_vec handlers
CPU 0
ksoftirqd/0
CPU 1
ksoftirqd/1
run_ksoftirqd
7. run_ksoftirqd checks the softirq_pending bit field
if pending
__do_softirq
8. __do_softirq executes the registered handler for the pending softirq
2. ksoftirqd processing loops are started.
Kernel
net_dev_init
net/core/dev.c
4. netdev_init registers softirq handler for NET_RX_SOFTIRQ called net_rx_action

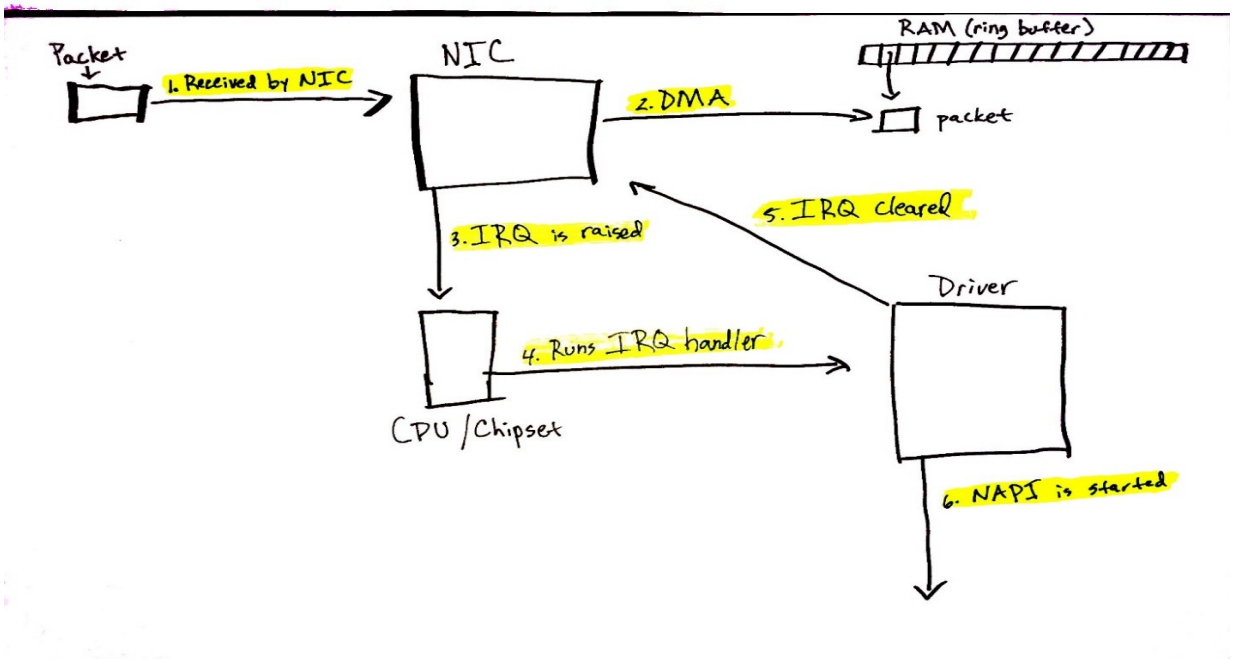
Packet
1. Received by NIC
NIC
RAM (ring buffer)
2. DMA
packet
3. IRQ is raised
5. IRQ cleared
Driver
4. Runs IRQ handler
CPU/Chipset
6. NAPI is started

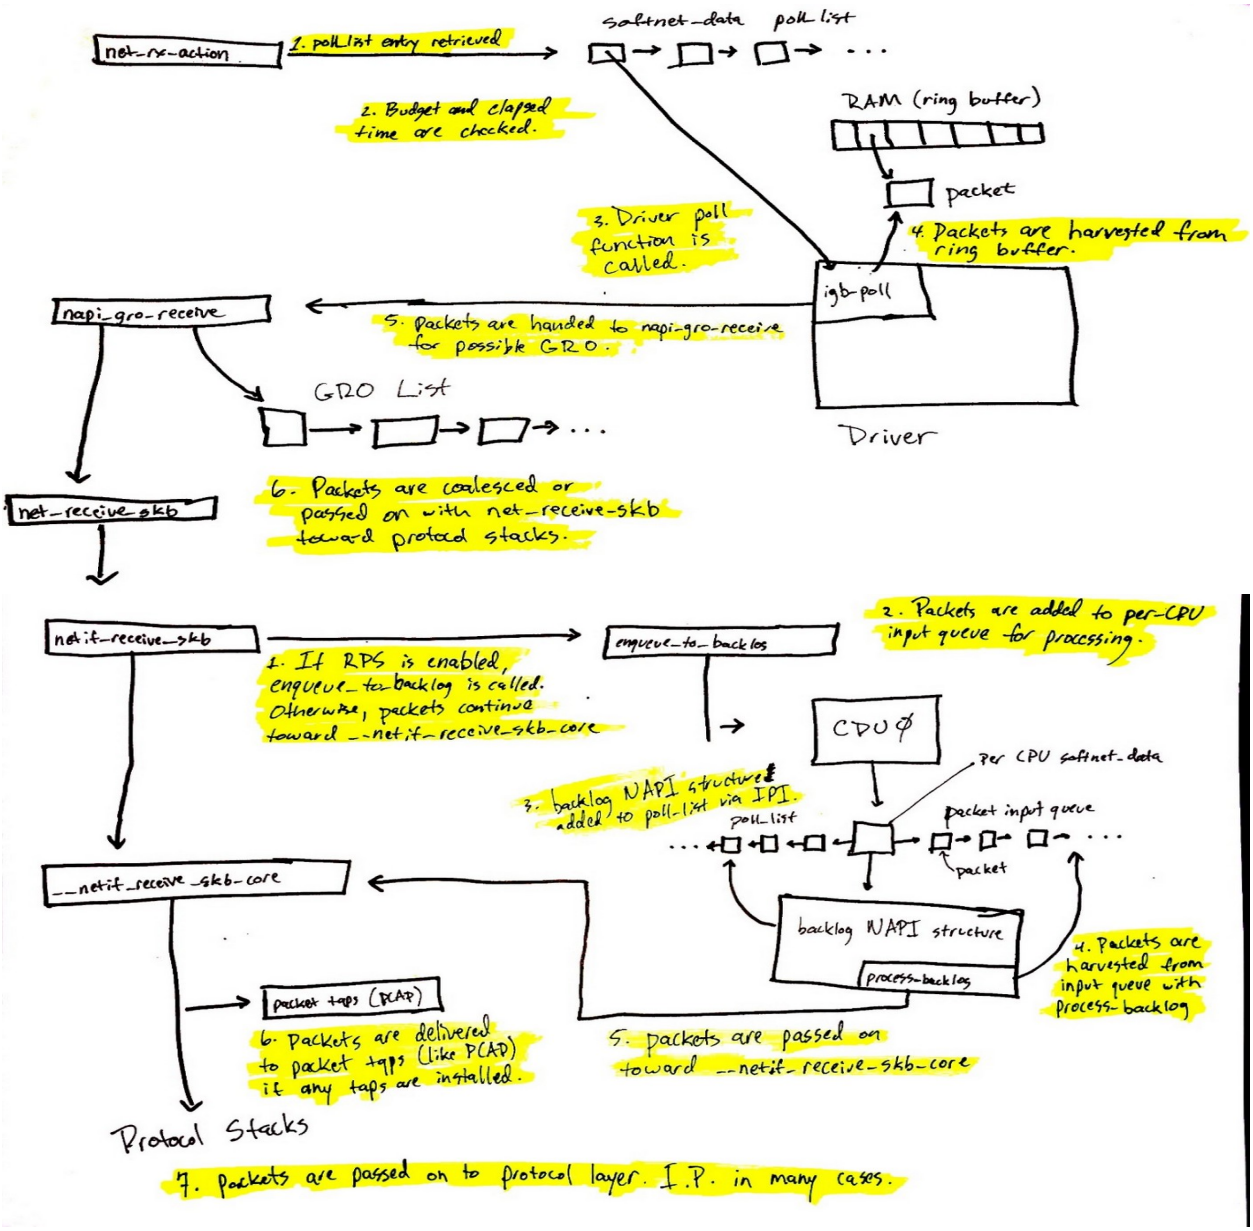
net_rx_action
1. poll list entry retrieved
softnet_data
poll_list
2. Budget and elapsed time are checked.
RAM (ring buffer)
packet
3. Driver poll function is called.
4. Packets are harvested from ring buffer.
igb_poll
napi_gro_receive
5. Packets are handed to napi_gro_receive for possible GRO.
GRO List
Driver
net_receive_skb
6. Packets are coalesced or passed on with net_receive_skb toward protocol stacks.
netif_receive_skb
1. If RPS is enabled, enqueue_to_backlog is called. Otherwise, packets continue toward __netif_receive_skb_core
enqueue_to_backlog
2. Packets are added to per-CPU input queue for processing.
CPU 0
Per CPU softnet_data
3. backlog NAPI structure added to poll_list via IPI.
poll_list
packet input queue
packet
__netif_receive_skb_core
backlog NAPI structure
process_backlog
4. Packets are harvested from input queue with process_backlog
packet taps (PCAP)
6. Packets are delivered to packet taps (like PCAP) if any taps are installed.
5. packets are passed on toward __netif_receive_skb_core
Protocol Stacks
7. packets are passed on to protocol layer. I.P. in many cases.